

Reporte de Selección y Parametrización de Modelos

Proyecto Aplicado en Analítica de Datos

Santiago Esteban Forero Hoyos,

César Martínez,

Sofia Salazar Suaza

Camila Alejandra Velasco Ruiz

Mayo 2024.

UNIVERSIDAD DE LOS ANDES.

DEPARTAMENTO DE INGENIERIA INDUSTRIAL

MAESTRIA EN INTELIGENCIA ANALITICA DE DATOS

Tabla de contenidos

Introducción.....	3
Preprocesamiento de datos	4
Modelos propuestos e implementación	7
1. DBSCAN con 3 features.....	7
2. DBSCAN con 7 features.....	9
3. DBSCAN con Regresión SVR simple.....	13
4. DBSCAN con Regresión SVR complejo	16
Pruebas de desempeño	21
Silhouette score.....	21
Índice de Davies-Bouldin	22
Índice de Calinski-Harabasz	23
Conclusiones.....	24
Elección de modelo final y justificación	24
Siguientes pasos	25
Referencias	27

Introducción

Contugas, filial del Grupo Energía Bogotá (GEB), es una empresa dedicada a la distribución y comercialización de gas natural en el departamento de Ica, Perú. Desde su creación en 2008, ha experimentado un crecimiento significativo, alcanzando más de 74.000 usuarios en 2022 y ampliando su red de distribución a más de 1.836 kilómetros (Caso Contugas, 2024). Sin embargo, a pesar de este desarrollo, la empresa enfrenta importantes desafíos financieros derivados de los elevados costos operativos, lo que ha generado pérdidas, a pesar del aumento en sus ingresos. Esta situación pone de manifiesto la necesidad urgente de optimizar sus procesos y mejorar la eficiencia operativa para asegurar su viabilidad a largo plazo (Caso Contugas, 2024).

En este contexto, este proyecto tiene como objetivo el desarrollo de un sistema de monitoreo inteligente para el consumo de gas de los clientes de Contugas, cuyo fin es detectar las anomalías que puedan indicar problemas como fugas, fallas en medidores o intervenciones externas. Este sistema se basará en la identificación de patrones de consumo típicos y atípicos en variables clave como la presión, temperatura y volumen de gas. De esta forma, puntualmente, el presente documento tiene como fin exponer el proceso de desarrollo de la detección de anomalías, mencionada anteriormente.

Principalmente, el modelo previsto a ser utilizado fue DBSCAN, un algoritmo de clustering no supervisado basado en densidad que busca agrupar puntos en un espacio de datos, identificando así regiones de alta densidad separadas por áreas de menor densidad. De esta forma, es capaz de clasificar puntos que no pertenecen a ningún grupo como ruido, por lo que es ideal en este caso para el propósito de detección de consumos anómalos de gas. Por otro lado, también se evaluó utilizar los modelos de Isolation Forest y K-Means. Con respecto a Isolation Forest, este modelo construye múltiples árboles aleatorios (isolation trees) y, de esta forma, los puntos anómalos son aislados de forma más rápida porque tienden a estar en regiones menos densas del espacio de datos. Por otro lado, K-Means es un algoritmo de clustering que divide los datos en k clústeres (predefinidos) minimizando la suma de distancias cuadradas entre los puntos y el centroide de su clúster, pero no es usado principalmente para encontrar anomalías. Sin embargo, de forma parecida a DBSCAN, se puede adaptar para este propósito ya que las anomalías se pueden identificar como puntos que están lejos de los centroides. Si bien ambos modelos pueden ser útiles, se decidió elegir DBSCAN por las siguientes razones:

1. Isolation Forest solo clasifica puntos como normales o anomalías, pero no agrupa los puntos normales. Es decir, en este sentido, la clusterización de DBSCAN no sólo permite encontrar outliers, sino que es útil para entender patrones de consumo normales al agruparlos en clústeres de alta densidad.
2. En línea con el punto anterior, DBSCAN ofrece una mayor interpretabilidad, pues las anomalías se definen como puntos fuera de los clústeres densos, lo que se puede ser más intuitivo y “user friendly” a la hora de explicarle visualmente al usuario el porqué de su consumo atípico. Por su parte, Isolation Forest depende de criterios internos de aislamiento, que son menos interpretables en términos de densidad.
3. Isolation Forest puede ser mejor cuando se trabaja con datos de altas dimensiones, cuando se requiere un modelo que procese grandes volúmenes de datos, o cuando las anomalías están muy dispersas. Sin embargo, dado que en este proyecto solo se está trabajando con 3 dimensiones (volumen, presión, temperatura), la cantidad de clientes es reducida y las anomalías son específicas a cada caso, no hay una necesidad evidente de utilizar un modelo más complejo como éste.
4. Como se explicó anteriormente, K-Means es un modelo parecido a DBSCAN, pero que no tiene como función principal encontrar anomalías. Adicionalmente, en K-Means, los clústeres deben ser predefinidos, mientras que en DBSCAN no, lo cual da más flexibilidad para no solo clusterizar el consumo por cliente, sino desentrañar en los patrones de consumo de cada uno. Por ejemplo, al tener clústeres flexibles, el modelo podría también detectar la estacionalidad del consumo de los clientes, agrupando así no solo por cliente, sino por cliente y época del año.

Ante las razones expuestas anteriormente, se concluyó que DBSCAN podría ser un mejor modelo porque ofrecía una mayor interpretabilidad y permitía que los consumos de los clientes se agruparan con respecto a sus patrones y no de una forma

predefinida que pudiera estar sesgada. No obstante, al momento de evaluar el modelo sobre distintas variables como temperatura, presión, mes, semana y volumen, los resultados no fueron los esperados, pues se estaban identificando como outliers observaciones puntuales, más no comportamientos generales. Ante esto, se decidió implementar una modelo SVR para modelar el comportamiento del volumen esperado de gas bajo condiciones "normales" dadas por los features elegidos y, posteriormente, aplicar DBSCAN sobre los errores absolutos para detectar puntos que se desviaran anormalmente (errores muy grandes entre el valor esperado y el observado). Sin embargo, este modelo seguía sin detectar “grupos” de outliers continuos que efectivamente alertaran sobre una posible fuga de gas, por lo que, finalmente, se complejizó de forma tal que se cumplieran estos requisitos, basándose en el artículo “*Outlier detection in time series using DBSCAN and SVR*” de PrincigHUB, 2024.

Preprocesamiento de datos

La base de datos con la que se contó para el desarrollo de este proyecto está conformada por el consumo histórico de 20 clientes, desde 2019 hasta 2023. Además del consumo (Volumen) de gas, también contiene el registro por hora y cliente de la temperatura y la presión de este. En términos generales, los modelos evaluados (DBSCAN y SVR) no requieren supuestos estadísticos estrictos como linealidad, independencia de los errores, normalidad, etc. Por lo que no se hicieron pruebas de ningún supuesto. No obstante, sí se hizo un análisis previo para entender el comportamiento de las variables y se calcularon dos variables a partir de la fecha: mes y día de la semana.

Tabla 1: Estadísticas descriptivas de las variables

	Presión	Temperatura	Volumen
count	847,960	847,960	847,960
mean	16.07	25.20	62.33
min	2.93	-5.26	0.00
25%	17.10	22.69	0.00
50%	17.57	25.38	21.77
75%	17.69	27.89	99.32
max	20.31	50.02	577.41
std	4.19	3.79	80.50

Gráfico 1: Distribución Volumen




Gráfico 2: Distribución Temperatura






Gráfico 3: Distribución Presión



Como se puede ver según la tabla 1 y gráficas 1-3, la variable principal (volumen) tiene datos muy dispersos, que van desde 0 a 577.41, mientras que la temperatura y la presión muestran un comportamiento más estable. Esto se debe a que la temperatura es una variable que depende del entorno y fuerzas externas como el clima, por lo que se puede ver un patrón claro en el que la temperatura aumenta en el invierno y disminuye en el verano posiblemente porque el gas se usa para calentar las instalaciones durante los periodos fríos. Se podría decir, entonces, que la temperatura y el volumen están correlacionados. No obstante, esta relación no es visible en las gráficas anteriores porque los patrones de consumo de todos los clientes son diferentes. Por esto, se graficarán las variables para el cliente 12 y, de esta forma, mostrar la relación entre el comportamiento de las variables:

Gráfico 4: Presión, Temperatura y Volumen del Cliente 12



Como se puede ver en el gráfico 4, parece haber una relación entre el volumen y la temperatura del gas, pero ningún patrón claro de la presión, que se mantiene constante o con cambios muy pequeños. Con el fin de confirmar la relación entre variables, se realizó una prueba de correlación entre ellas para cada cliente:

Tabla 2: Correlación entre variables principales

Cliente	Correlación Presión-Volumen	P-Valor	Correlación Temperatura-Volumen	P-Valor
1	0.00	0.63	0.28	0.00
2	0.02	0.00	-0.05	0.00
3	-0.58	0.00	-0.14	0.00
4	0.01	0.06	-0.02	0.00
5	-0.38	0.00	0.37	0.00
6	-0.17	0.00	0.33	0.00
7	-0.35	0.00	0.74	0.00
8	-0.88	0.00	0.53	0.00
9	-0.69	0.00	0.06	0.00
10	-0.53	0.00	-0.02	0.00
11	-0.61	0.00	-0.13	0.00
12	-0.36	0.00	0.78	0.00
13	-0.56	0.00	-0.06	0.00
14	-0.45	0.00	0.30	0.00
15	-0.77	0.00	0.00	0.53
16	-0.83	0.00	0.53	0.00
17	0.01	0.01	0.12	0.00
18	0.03	0.00	-0.02	0.00
19	-0.02	0.00	0.02	0.00
20	-0.05	0.00	0.36	0.00
Promedio	-0.36		0.20	

Como se puede ver, la correlación promedio por cliente entre volumen y temperatura es de 0.20, mientras que el promedio entre volumen y presión es de -0.36, con una significancia del 5% en la mayoría de los casos. Esto confirma lo explorado anteriormente sobre el impacto positivo de la temperatura sobre el volumen. Sin embargo, contrario a lo que se había


observado, el impacto de la presión parece ser mayor que la de la temperatura sobre el volumen, aunque con una relación negativa. Es decir, la presión parece estar más correlacionada con el consumo de gas que la temperatura. La implementación de estas variables será explorada a lo largo de la implementación de los modelos evaluados.

Modelos propuestos e implementación

1. DBSCAN con 3 features

El primer modelo evaluado fue un DBSCAN que se utilizó para agrupar los datos en las tres dimensiones principales de la base de datos de los clientes y, de esta forma, encontrar clústeres de consumo y outliers. Para esto, se construyó una función que recibía los datos (escalándolos apropiadamente) y la lista de variables de interés y asignaba un clúster para cada registro. Como se mencionó en el preprocesamiento de datos, el comportamiento de consumo de cada cliente es diferente, por lo que no se pueden aplicar los modelos a todos los datos en conjunto. Por esta razón, éste y los siguientes modelos iteran los datos cliente por cliente. Por ejemplo, en este caso, la iteración involucró calcular un eps óptimo por cada cliente para poder encontrar los parámetros óptimos del modelo DBSCAN. Esto implica que cada a cada cliente se le aplica un modelo DBSCAN con parámetros optimizados según sus datos. Por ejemplo, en la siguiente gráfica se puede ver el ‘Knee Graph’ que muestra el eps óptimo del cliente 1:

Gráfico 5: Knee-Graph Cliente 1 – Modelo 1



Con respecto al parámetro min samples, éste se eligió multiplicando el número de features (3) por 2. Es decir, este parámetro tomó un valor de 6 para todos los clientes, lo que quiere decir que debe haber al menos 5 otros consumos cercanos (según el valor de eps) para que se forme un clúster.

De esta forma, tras aplicar el modelo en los datos de todos los clientes, podemos ver los resultados a continuación:


En primer lugar, observemos el número de clústeres por cada cliente:

Tabla 3: Número de clústeres por cliente (Modelo 1)

Cliente	Número de Clústeres
1	5
2	6
3	2
4	8
5	4
6	7
7	3
8	3
9	4
10	3
11	2
12	4
13	4
14	5
15	2
16	4
17	9
18	14
19	8
20	4

Con un promedio de 5 clústeres por cliente, se podría pensar que este número es un poco bajo, considerando que se está intentando capturar el comportamiento de una serie de tiempo con datos de 2019 a 2023 y con una frecuencia por hora. Es decir, parece que el modelo está generalizando el consumo de cada cliente en unos pocos subgrupos, lo que puede implicar que los outliers no estén siendo correctamente identificados. Como ejemplo, se procederá a estudiar los resultados del cliente 12:

Gráfico 6: Resultados Modelo 1 – Cliente 12



Como se puede ver, el modelo no está siendo eficiente en identificar ni los outliers ni los clústeres de consumo. Por un lado, se puede ver que la mayoría de outliers están sobrepuestos sobre grandes densidades de datos continuos, lo que es contraintuitivo. Por otro lado, los clústeres están generalizando la mayoría de los datos en dos grupos extremos: alto (morado) y bajo (rojo) consumo. No se puede evidenciar que haya un clúster con

comportamiento atípico en particular. De forma similar, se pueden observar los clientes 11 y 18, que tuvieron un número muy diferente de clústeres, pero sin resultados concluyentes:

Gráfico 7: Resultados Modelo 1 – Cliente 11





Gráfico 8: Resultados Modelo 1 – Cliente 18




Es decir, el modelo se está concentrando en encontrar (erróneamente) consumos aislados atípicos en lugar de mostrar patrones de clústeres o grupos de consumos atípicos.

2. DBSCAN con 7 features

Teniendo en cuenta los resultados del modelo anterior, se puede decir que la temperatura, la presión y el volumen no son suficientes para agrupar patrones de consumo de gas. Por esto, dado que la única otra variable disponible en los datos es la fecha, se decidió incluir componentes temporales. Como se vio en el preprocesamiento de datos, se puede esperar que se gaste más gas en los meses de invierno (finales y principio de año) o entre semana (donde ocurre la mayor actividad industrial). Por esto, se agregaron las siguientes variables: mes, día de la semana, semana del año, fin de semana. Con esto, se esperó que el agrupamiento de los datos fuera más eficiente.

Tal como en el modelo 1, éste se aplicó a cada cliente dependiendo del ϵ ps óptimo de cada uno, con un $\min$ sample de $2 \times 7 = 14$, dado que se tienen 7 dimensiones. A continuación, se muestran los resultados:

Gráfico 9: Knee-Graph Cliente 1 – Modelo 2




Como se puede ver, el eps óptimo del cliente 1 aumentó de 0.187 a 0.581, lo que significa que la distancia mínima para que dos puntos pertenezcan al mismo clúster, aumentó. Esto puede implicar que el número de clústeres ahora será mayor, lo cuál se evaluará a continuación:

Tabla 4: Número de clústeres por cliente (Modelo 2)

Cliente	Número de Clústeres
1	8
2	5
3	3
4	6
5	4
6	8
7	3
8	4
9	3
10	8
11	3
12	3
13	4
14	6
15	4
16	4
17	12
18	8
19	13
20	7


Para este modelo, el promedio de clústeres por cliente aumentó a 5.8, lo cual no es muy diferente al anterior (5) y sigue considerándose bajo. Procedemos a visualizar los resultados de algunos clientes:

Gráfico 10: Resultados Modelo 2 – Cliente 12



Como se puede ver, el número de clústeres para el cliente 12 no cambió drásticamente. Sin embargo, la distribución de los datos con respecto a éstos parece seguir un nuevo patrón. Para notarlo, haremos zoom al año 2021:

Gráfico 11: Resultados Modelo 2 – Cliente 12 – Año 2021



Como se puede observar, el modelo ya no está agrupando los datos por altos o bajos consumos, sino que parece estar separándolos por semanas o días en dos grupos principales, y está marcando como outlier los días que no se acoplan a ninguno de éstos. Si bien esto se acerca más al objetivo del proyecto para identificar potenciales fugas de gas, aún se puede ver mucho ruido en los resultados, lo que implica muchos potenciales falsos positivos. Verificamos esto con los clientes 11 y 18:

Gráfico 12: Resultados Modelo 2 – Cliente 11





Gráfico 13: Resultados Modelo 2 – Cliente 18 – noviembre 2019 a septiembre 2020



Tanto en el cliente 11 como en el 18 se puede notar una clara división intercalada de periodos cortos de tiempo que, en su mayoría, se adaptan a dos clústeres principales. En el caso del cliente 18, se detectan clústeres de datos adicionales, pero siguen predominando dos (0 y 1), como en los clientes 11 y 12. Esto es de interés, dado que aquellos clústeres “atípicos” podrían ser, precisamente, clústeres outlier, teniendo en cuenta que una fuga de gas puede durar muchas horas consecutivas y no solo una. Por otro lado, si bien es importante detectar los outliers aislados, éstos no son realmente un reflejo de una fuga de gas, pues, como se mencionó anteriormente, éstas suelen durar más de un registro. Ante esto, los siguientes esfuerzos se centrarán en mejorar la forma en la que se identifican los clústeres de consumo de gas.

3. DBSCAN con Regresión SVR simple

Hasta ahora hemos afrontado dos desafíos principales: en primer lugar, no se ha logrado modelar correctamente los patrones de consumo de los clientes de forma tal que se puedan identificar comportamientos atípicos y, en segundo lugar, hay mucho ruido en los resultados con respecto a los outliers. Con el fin de intentar superar estos retos, se decidió modelar el comportamiento del volumen esperado de gas bajo condiciones “normales” dadas por los features elegidos con una regresión SVR para capturar relaciones no lineales o complejas. De esta forma, para cada punto, se calculará el error residual entre el valor esperado dado por SVR y el valor observado del volumen de gas. Posteriormente, se aplicará DBSCAN sobre estos errores residuales y se buscará aislar o detectar aquellos que sean más grandes. Es decir, en lugar de etiquetar como outlier cualquier punto que se aleje de la media (lo que está causando mucho ruido en los modelos anteriores), se detectarán outliers solo si pertenecen a un patrón anómalo sistemático en el espacio residual. Así, esto filtra gran parte del ruido aleatorio.

El modelo es, en general, parecido a los dos anteriores. La única diferencia es que primero se aplica un modelo SVR para modelar el volumen en función de la temperatura, la presión, el mes, el día de la semana y la semana del año, y luego se calculan los errores residuales entre la predicción y el valor observado del volumen para, posteriormente, aplicar el modelo DBSCAN sobre éstos. Tal como en los anteriores modelos, se itera cliente por cliente y se calcula el ϵ óptimo para cada uno. Dado que solo se está usando el feature de residuo para DBSCAN, se utiliza un $\min$ samples bajo de 5. A continuación se aprecian los resultados:


Tabla 5: Número de clústeres por cliente (Modelo 3)

Cliente	Número de Clústeres
1	2
2	2
3	2
4	17
5	3
6	3
7	4
8	3
9	4
10	12
11	2
12	3
13	18
14	5
15	4
16	8
17	6
18	2
19	17
20	2

En este modelo, el número promedio de clústeres subió a 5.95. Aunque el promedio aumentó, la cantidad sigue siendo un poco baja para segregar correctamente los patrones de consumo de gas con el fin de encontrar grupo anómalos. Sin embargo, revisaremos los resultados:

Gráfico 14: Resultados Modelo 3 – Cliente 12


Cliente: CLIENTE12 - Volumen vs Fecha



Como se puede observar, aparentemente, uno de los dos desafíos fue superado con este modelo, pues el ruido disminuyó significativamente. Sin embargo, el otro reto no fue superado dado que los clústeres no están clasificando los datos históricos en subgrupos por magnitudes de residuos. Esto puede deberse, quizás, a la falta de un factor temporal para alimentar el modelo DBSCAN. Por ejemplo, observemos la siguiente ventana de tiempo:

Gráfico 15: Resultados Modelo 3 – Cliente 12 – enero 2023


Cliente: CLIENTE12 - Volumen vs Fecha



Alrededor de enero 29 se puede observar que hay seis puntos atípicos (considerando al clúster 1 como atípico dado que es poco usual). ¿Si bien son atípicos por separado, se podría concluir que son evidencia de que hubo una fuga de gas alrededor de esa fecha? Probablemente no, dado que cada uno ocurrió en una fecha diferente, por lo que el comportamiento atípico no fue continuo ni estuvo concentrado en una densidad específica de los datos. Esto último es en lo que sigue fallando el modelo, pues es incapaz de responder la pregunta por sí mismo. Procedemos a revisar los resultados de otros dos clientes para ver el comportamiento del modelo:

Gráfico 16: Resultados Modelo 3 – Cliente 11


Cliente: CLIENTE11 - Volumen vs Fecha



Al igual que en el cliente 12, el modelo logra identificar satisfactoriamente datos atípicos, pero no patrones de comportamiento atípicos (o típicos, en su defecto).

Gráfico 17: Resultados Modelo 3 – Cliente 13

Cliente: CLIENTE13 - Volumen vs Fecha



Para el cliente 13, sí se logran detectar varios patrones en los datos, probablemente debido a su naturaleza de alta dispersión. Sin embargo, nuevamente, si bien se detectan outliers, no es evidente cuál clúster de datos es atípico para concluir sobre una posible fuga de gas.

En conclusión, este modelo parece ser muy eficiente en detectar outliers aislados, pero no detectar patrones de comportamiento atípicos.

4. DBSCAN con Regresión SVR complejo

El último modelo que se evaluará intenta capturar lo útil de los modelos anteriores y superar el último reto por cumplir, que es modelar correctamente los patrones de consumo de gas de los clientes por medio de clústeres. Para esto, se seguirá trabajando con un modelo DBSCAN y se seguirán modelando los datos con SVR, pero esta vez de una forma diferente. En primer lugar, en el modelo 3 se reconoció que se había superado el reto de disminuir el ruido porque ya no se estaban detectando muchos outliers. Sin embargo, esto ocurrió porque se entrenó un modelo SVR con los mismos datos que se utilizaron para hacer la predicción. Es decir, era de esperarse que el modelo brindara residuales muy pequeños porque el modelo no se aplicó sobre nuevos datos. Si bien esto no es necesariamente erróneo, no funcionó para el propósito de encontrar clústeres con muchos puntos atípicos, pues no existían. Para evitar cometer este error nuevamente, se decidió entrenar el SVR quitando los filamentos de outliers más predominantes para, de esta forma, modelar un comportamiento “normal” del consumo de gas contra el que se pudieran comparar los registros observados. Ante esto, basado en el artículo de PriceHub, 2024, se construyó el siguiente algoritmo:

1. Rescatado del modelo 2, se agregan dos columnas temporales a la base de datos (mes y día de la semana) basado en la fecha.
2. Se define una iteración por cliente
3. Se remplazan los valores nulos (NA) de temperatura, presión y volumen por valores extremos (100 veces el máximo valor observado) para que se comporten como outliers
4. Se preparan las variables predictoras:
 - a. Se calcula una variable x_{seq} que es una secuencia temporal que asigna un número a cada fecha y sirve para mejorar los clústeres
 - b. Siempre se usan Mes, Dia Semana y x_{seq}
 - c. Opcionalmente, se usan Temperatura o Presión
5. Se preparan los modelos:
 - a. Se entrena una regresión SVR con todas las variables predictoras, excepto x_{seq} dado que Mes y Dia Semana ya otorgan el componente temporal
 - b. Se utiliza DBSCAN para encontrar los clústeres usando x_{seq} , Mes, Dia_semana y Volumen.
6. Iteración de los modelos:
 - a. Se escalan las variables para el modelo DBSCAN
 - b. Se estima el ϵ ps óptimo por cliente y se usa $\min \text{ simples} = 8$ ya que se usarán cuatro dimensiones.
 - c. Se detectan los clústeres de inliers (puntos normales) y los outliers aislados
 - d. Se entrena el modelo SVR excluyendo los outliers detectados en el paso anterior
 - e. Se calcula el error absoluto entre lo observado y la predicción de SVR para cada registro y se hace un promedio por clúster
 - f. Se define un umbral para identificar residuales altos. Este umbral es el 5% del máximo registro de volumen de cada cliente. Por ende, depende de los datos del cliente y no es fijo.
 - g. Se identifica el clúster con el mayor residual promedio. Si supera el umbral definido en el paso anterior, se marcan esos puntos como outliers y se marcan como NA en el conjunto de entrenamiento.
 - h. Se repiten los pasos 6.a-6.g hasta que el promedio residual de ningún clúster supere el umbral definido.
7. Se utiliza el último modelo SVR entrenado sin filamentos o clústeres de outliers para predecir el volumen para todos los registros del cliente
8. Se aplica un DBSCAN final con todos los datos originales para las dimensiones Mes, Dia Semana y Volumen para poder visualizar los clústeres.

9. Se guarda en una base de datos los registros originales, el volumen predicho, el error MSE, la clasificación de outlier y el clúster asignado por DBSCAN.

Una vez se corrió este algoritmo, se obtuvieron los siguientes números de clústeres:

Tabla 6: Número de clústeres por cliente (Modelo 4)

Cliente	Número de Clústeres
1	1,812
2	415
3	1,798
4	1,799
5	1,814
6	1,801
7	442
8	1,816
9	1,798
10	1,759
11	1,798
12	489
13	515
14	1,814
15	1,798
16	1,814
17	424
18	415
19	1,800
20	1,801

Con un promedio de 1,396, éste es el modelo con el mayor número de clústeres, lo cual es un buen indicio ya que puede significar que agregar la secuencia de fechas permite que el modelo capture el componente temporal de la serie de tiempo adecuadamente junto con la estacionalidad dada por las variables de mes y día semana. De esta forma, se puede diferenciar un jueves de marzo del 2020 de un jueves de marzo de 2023. Ahora procederemos a visualizar los resultados de algunos clientes para evaluar si los patrones de comportamiento están siendo, efectivamente, detectados de esta forma.

Gráfico 18: Resultados Modelo 4 – Cliente 12





Gráfico 19: Resultados Modelo 4 – Cliente 11




Como se puede ver en los gráficos 18 y 19, los registros de los clientes 11 y 12 ahora están evidentemente agrupados en clústeres según su patrón de comportamiento con respecto al volumen, el mes, el día de la semana, y la secuencia temporal. Adicionalmente, se puede ver en gris las predicciones del modelo SVR entrenado sin filamentos de outliers. Los outliers aislados están representados con un triángulo naranja y los filamentos de outliers (los clusters con promedios residuales mayores a los umbrales de cada cliente), con cruces rojas. En el primer caso, el cliente 12 tiene un comportamiento estacionario, sin mucha dispersión y con una periodicidad constante. Esto implica que no tuvo muchos comportamientos atípicos que influyeran drásticamente en las predicciones del modelo SVR, por lo cual vemos que éstas se acercan mucho a los valores reales. Las únicas diferencias de gran magnitud se dan en febrero de 2021, donde se evidencia un filamento con alta densidad de

outliers que será estudiado en la herramienta final para asignarle una probabilidad de que representa una potencial fuga de gas según la magnitud de sus residuales.


Por otro lado, el cliente 11 no muestra una periodicidad tan constante como el 12, pero si una estacionariedad. Por esta razón, sus datos son un poco más dispersos y los valores predichos por SVR no se acercan tanto a cada punto. Sin embargo, la predicción SVR logra marcar una tendencia normal hipotética que marca al 2021 como un año atípico al no seguir los patrones de comportamiento que los otros años habían estado teniendo. Si bien se sabe que el año completo no pudo haber tenido fugas de gas, sí nos da una herramienta de entrada para ahondar en estos datos e inspeccionar los filamentos más alejados de las predicciones para definir su probabilidad de haber sido una fuga de gas.

Gráfico 20: Resultados Modelo 4 – Cliente 18



El caso del cliente 18 es interesante y muy diferente a los dos anteriores. Acá se tiene un comportamiento estable y constante a lo largo de todos los años, sin ninguna interrupción evidente. Sin embargo, el modelo identificó un grupo de datos particular en febrero de 2023 que tiene residuales promedios mayores al resto de clústeres. Estos datos probablemente no representan una fuga de gas, pero eso es algo que la herramienta que está en desarrollo para analizar los resultados del modelo definirá. No obstante, se puede evidenciar que no hay ningún otro clúster candidato a ser una fuga.

Gráfico 21: Resultados Modelo 4 – Cliente 13



Los resultados del modelo se convierten más difíciles de interpretar en casos como el del cliente 13, que tiene una alta dispersión de datos, sin ningún patrón o estacionariedad clara. Si bien el modelo logró detectar un filamento de outliers en noviembre de 2022, la naturaleza de estos datos es tan heterogénea y dispersa, que puede haber muchos falsos positivos. Casos como éste serán un desafío para que la herramienta final pueda interpretar sus resultados.

Pruebas de desempeño

Con el fin de evaluar el desempeño de los cuatro modelos, se eligieron métricas de desempeño aptas para modelos de clustering dado que la base de todos es DBSCAN.

Silhouette score

Esta métrica es una medida de la similitud entre un punto y los otros puntos de datos en su propio grupo comparación con otros grupos. Entre más cercano a 1, mejor es el desempeño del modelo.

Los resultados de esta métrica por modelo y cliente fueron los siguientes:

Tabla 7: Silhouette score Modelos 1-4

Cliente	Silhouette Score			
	Modelo 1	Modelo 2	Modelo 3	Modelo 4
1	0.289	0.147		-0.118
2	0.225	0.198		0.018
3		0.272		-0.132
4	0.581	0.299	0.909	0.586
5	0.497	0.252	0.854	-0.130
6	0.393	0.204	0.715	-0.120
7	0.024	0.279	0.703	0.598
8	-0.045	0.231	0.804	-0.127
9	0.35	0.29	0.91	0.47
10	0.099	0.023	0.906	0.565
11		0.274		-0.151
12	0.075	0.279	0.747	0.610
13	0.149	0.260	0.920	0.861
14	0.484	0.147	0.702	-0.136
15		0.240	0.911	0.388
16	-0.101	0.230	0.763	-0.135
17	0.163	-0.046	0.725	0.099
18	-0.009	0.182		0.012
19	0.317	0.038	0.942	0.638
20	0.392	0.144		-0.132
Promedio	0.228	0.197	0.822	0.183

Índice de Davies-Bouldin

Esta métrica es una medida de la similitud promedio entre cada grupo y su grupo más similar. Entre más bajo, mejor es el desempeño del modelo.

Los resultados de esta métrica por modelo y cliente fueron los siguientes:

Tabla 8: Índice de Davies-Bouldin Modelos 1-4

Cliente	Davies-Bouldin Score			
	Modelo 1	Modelo 2	Modelo 3	Modelo 4
1	0.756	1.037		15.276
2	0.709	1.216		4.166
3		1.561		12.290
4	0.623	1.172	0.401	1.967
5	0.748	1.339	0.111	34.812
6	0.615	1.097	0.175	54.237
7	1.081	1.553	0.309	0.843
8	1.182	1.361	0.125	49.695
9	0.596	1.498	0.117	2.204
10	0.810	8.014	0.420	2.072
11		1.555		13.828
12	0.977	1.555	0.176	0.866
13	0.595	1.289	0.434	0.589
14	0.750	1.061	0.286	29.329
15		1.343	0.133	2.706
16	1.199	1.339	0.352	39.793
17	0.870	1.125	0.342	2.563
18	0.751	1.003		4.070
19	0.529	1.335	0.383	2.004
20	0.521	1.084		47.631
Promedio	0.783	1.627	0.269	16.047

Índice de Calinski-Harabasz

Esta métrica es una medida de la relación entre la varianza entre conglomerados y la varianza dentro del conglomerado. Entre más alto, mejor es el desempeño del modelo.

Los resultados de esta métrica por modelo y cliente fueron los siguientes:

Tabla 9: Índice de Calinski-Harabasz Modelos 1-4

Cliente	Calinski-Harabasz Score			
	Modelo 1	Modelo 2	Modelo 3	Modelo 4
1	5,998.24	3,368.30		455.38
2	4,723.79	4,179.97		347.54
3		12,519.18		559.66
4	11,076.79	5,709.67	257,693.90	285.26
5	9,623.58	7,964.24	431.38	106.57
6	4,112.98	4,229.01	154.28	80.18
7	21.15	12,330.35	937.50	5,741.41
8	20.25	6,484.91	280.26	75.03
9	786.95	11,787.35	1,572.72	319.56
10	12.29	2,508.14	60,650.08	296.76
11		12,538.80		292.83
12	23,925.65	12,388.08	372.08	5,950.34
13	69.17	5,795.09	40,907.51	13,608.08
14	7,278.02	3,622.44	458.94	151.46
15		5,999.41	602.49	244.76
16	222.85	6,462.98	1,271.69	79.41
17	2,569.06	1,958.00	544.79	1,017.46
18	1,846.17	3,423.32		348.55
19	10,906.90	2,289.23	148,105.79	330.71
20	1,415.77	2,841.34		72.17
Promedio	4,977.04	6,419.99	36,713.10	1,518.16

Conclusiones

Elección de modelo final y justificación

Como se pudo ver en la sección anterior, las métricas de desempeño promedio para cada modelo fueron:

Tabla 10: Métricas de desempeño promedio por modelo

	Modelo 1	Modelo 2	Modelo 3	Modelo 4
Silhouette Score	0.228	0.197	0.822	0.183
Davies-Bouldin Score	0.783	1.627	0.269	16.047
Calinski-Harabasz Score	4,977	6,420	36,713	1,518

Evidentemente, el modelo 4 presentó métricas de desempeño significativamente más bajas en comparación con los otros modelos. Sin embargo, se debe recalcar que los modelos 1 a 3 tuvieron un número de clústeres promedio entre 5 y 6, mientras que el modelo 4 tuvo un promedio de 1,396. Un número bajo de clústeres favorece métricas como Silhouette y Calinski porque estas métricas están diseñadas para evaluar separaciones entre un número moderado de grupos bien definidos. Como vimos en los resultados de los modelos 1 a 3, la mayoría de los datos estaba agrupada en muy pocos clústeres, mientras que el modelo 4 calculó muchos grupos pequeños, lo cual es penalizado por las métricas basadas en distancia promedio intra e inter-clúster. Por ejemplo, el Silhouette Score penaliza los puntos que están muy cerca de otros clústeres, y con tantos grupos pequeños, los puntos no tienen suficiente estructura para mostrar cohesión o separación claras. Esto es evidente en los resultados del modelo 4, donde la distribución de clústeres parece un arco iris. Por otro lado, el Davies-Bouldin Score empeora porque compara la dispersión de los clústeres con su distancia entre ellos, y con muchos clústeres cercanos y pequeños, este valor tiende a crecer. Finalmente, el Calinski-Harabasz Score disminuye por la baja varianza entre clústeres en relación a la dispersión interna en clusters tan reducidos.

Teniendo en cuenta lo anterior, el hecho de que el modelo 4 tenga los valores menos favorables de estas métricas no significa que sea el peor modelo. Por el contrario, el objetivo del proyecto es identificar micro clústeres o comportamientos específicos en los datos que los modelos 1, 2 y 3 no capturan, como lo evidencian sus métricas. Finalmente, si se analizan las métricas del modelo 4 individualmente, se puede ver que no son indeseables. Por ejemplo, su Silhouette Score está por encima de 0, el Davies-Bouldin Score es bajo y el el Calinski-Harabasz Score es alto. En este sentido, valdría la pena evaluar el modelo 4 bajo diferentes parámetros y encontrar los que optimicen estas métricas.


Ante los argumentos expuestos en esta sección y los resultados de los modelos, se decide elegir el modelo 4 debido a su capacidad de identificar patrones de comportamiento en el consumo de gas por parte de los clientes. Si bien esto hace que se calculen muchos clústeres en densidades grandes de datos (debido a la naturaleza de estos) y, por ende, las métricas sean penalizadas, se debe considerar el objetivo principal que es predecir en qué periodos cortos de tiempo pudo haber o habrá fugas de gas, lo cual no podría lograrse separando los datos en unos pocos subgrupos con muchos datos. No obstante, no se descartan los esfuerzos para mejorar estas métricas en el modelo 4 por medio de una optimización de parámetros como min simples (dado que eps ya está siendo optimizado).

Siguientes pasos

Con el pipeline automatizado ya implementado para la detección de patrones anómalos en el consumo de gas, se identifican los siguientes componentes pendientes para completar el prototipo funcional y asegurar una entrega efectiva del producto final:

Item	Actividad	Descripción	Fecha
1	Desarrollo de la interfaz de usuario y tablero interactivo	Ya se cuenta con un primer boceto de la herramienta, el cual será implementado en Dash y desplegado sobre Railway o Amazon Web Services (AWS) – Elastic Beanstalk o EC2. Esta plataforma permitirá a los usuarios: • Consultar los resultados de detección de outliers por cliente y por periodo de tiempo. • Visualizar la comparación entre los valores reales y predichos del volumen de gas. • Filtrar alertas por severidad o fecha (para la severidad se encuentra pendiente definir el modo de clasificación según los resultados del modelo)	16/05/2025
2	Evaluación del prototipo en entorno de prueba	El prototipo se ejecutará en Railway o Amazon Web Services (AWS) – Elastic Beanstalk o EC2 simulando datos reales por lotes (modo batch), con el fin de: • Verificar la estabilidad del sistema. • Evaluar el tiempo de respuesta del pipeline ante nuevos registros. • Validar que los outputs del sistema sean consistentes y coherentes con los casos de prueba definidos.	18/05/2025
3	Alistamiento de entregables y documentación técnica	Se debe consolidar: ○ Manual técnico de uso del sistema. ○ Descripción del modelo y lógica de clasificación. ○ Presentación ejecutiva para stakeholders.	21/05/2025

La primera aproximación de la herramienta sobre Dash, se muestra a continuación:



Referencias

PricingHUB. (2024, mayo 9). Outlier detection in time series using DBSCAN and SVR. Medium.
<https://pricinghub.medium.com/outlier-detection-in-time-series-using-dbscan-and-svr-09b43d0cadcl>