


Propuesta de detección de fugas de gas para la empresa Contugas



Contenidos

- ▶ Contexto
- ▶ Solución propuesta
- ▶ Resultados
- ▶ Entregables & demo
- ▶ Propuesta de valor

Contexto

- ▶ **Contugas** es una empresa del Grupo Energía Bogotá dedicada a la distribución de gas natural en Ica, Perú, con más de **74,000 usuarios** y una red de **1,836 km** al 2022.
- ▶ A pesar del crecimiento, enfrenta **desafíos financieros** por altos costos operativos, lo que genera la necesidad urgente de **mejorar la eficiencia operativa**.
- ▶ En respuesta, se plantea el desarrollo de un **sistema inteligente de monitoreo de consumo de gas**, enfocado en **detectar anomalías** como:
 - Fugas
 - Fallas en medidores
 - Intervenciones externas

Contexto

- ▶ Se evaluaron distintos modelos de detección de anomalías (DBSCAN, Isolation Forest, K-Means), eligiendo **DBSCAN** por su:
 - Capacidad de detectar **outliers basados en densidad**
 - Mayor **interpretabilidad visual**
 - Flexibilidad para descubrir patrones sin predefinir el número de clústeres
- ▶ Tras experimentar con DBSCAN y SVR, se refinó la solución inspirándose en un enfoque híbrido de la literatura (PricingHUB, 2024.) para **mejorar la detección de patrones anómalos continuos**.

Resultados esperados

Aspecto	Resultado Esperado	Criterio / Métrica de Evaluación	Resultado
Analítica	Detección de eventos críticos no identificados previamente	Cobertura $\geq 90\%$ de eventos históricos críticos detectados	Se aplicó el modelo sobre el 100% de los datos.
	Satisfacción del cliente con alertas y dashboard	Valoración $\geq 4/5$ en encuestas; tareas completadas sin ayuda en < 1 minuto	Pendiente, se requiere después del go live de la app
Desempeño del modelo	Identificación de patrones de consumo normales y anómalos	- Silhouette > 0 - Davies-Bouldin mínimo - Calinski-Harabasz máximo	No se cumplió en su totalidad
Funcionalidad	Visualización clara y coherente de resultados en el dashboard	Coincidencia $\geq 95\%$ entre visualización y resultados del modelo	Se desarrolló dashboard en Dash con gráficas interactivas. Validación visual vs. resultados del modelo fue $\geq 95\%$.
Infraestructura	Operatividad estable en entorno Railway o AWS	Uptime $\geq 99\%$ durante la simulación en ambos entornos	Se desplegó el sistema en Railway. Uptime observado $> 99\%$ durante prueba de carga simulada.
	Tiempo de respuesta ante nuevos registros	Procesamiento batch en ≤ 5 segundos	Simulación batch procesada en $< 5s$. Se optimizó el pipeline para reducir fluctuaciones.
Usabilidad	Navegación intuitiva del dashboard interactivo	Tareas completadas sin ayuda en < 1 minuto; respuesta a filtros en < 2 segundos	Pendiente, se requiere después del go live de la app

Solución Propuesta

- ▶ Se evaluaron cuatro modelos:
 - ▶ DBSCAN con 3 features (volumen, presión, temperatura)
 - ▶ DBSCAN con 7 features (volumen, presión, temperatura, mes, día semana, semana del año, fin de semana)
 - ▶ DBSCAN con Regresión SVR simple (clusters de residuales)
 - ▶ DBSCAN con Regresión SV complejo (clusters removiendo outliers según residuales)

Gráfico 6: Resultados Modelo 1 – Cliente 12

Cliente: CLIENTE12 - Volumen vs Fecha





Gráfico 14: Resultados Modelo 3 – Cliente 12

Cliente: CLIENTE12 - Volumen vs Fecha



Solución Propuesta

► Modelo seleccionado: DBSCAN con Regresión SVR Complejo:

1. Iteración por cliente:

- Se ajusta un modelo **SVR** para estimar el volumen esperado
- Se aplica **DBSCAN** para identificar clústeres densos y puntos aislados (outliers)
- Se excluyen los outliers y se recalibra el modelo SVR para mejorar la predicción

2. Detección de anomalías:

- Se calcula el **residual absoluto** (predicho vs. real)
- Se evalúa si hay clústeres con residuales altos (potencialmente anómalos)
- Se repite el proceso hasta que no haya clústeres con errores residuales críticos

3. Clasificación de riesgo de fuga:

- Los clústeres detectados como *outliers* se clasifican en **riesgo Bajo, Medio o Alto**, según el residual promedio.
- El umbral se adapta por cliente (percentiles), garantizando sensibilidad específica.

Gráfico 18: Resultados Modelo 4 – Cliente 12





Gráfico 19: Resultados Modelo 4 – Cliente 11



Resultados

Tabla 10: Métricas de desempeño promedio por modelo

	Modelo 1	Modelo 2	Modelo 3	Modelo 4
Silhouette Score	0.228	0.197	0.822	0.183
Davies-Bouldin Score	0.783	1.627	0.269	16.047
Calinski-Harabasz Score	4,977	6,420	36,713	1,518

- ▶ El **Modelo 4** presentó métricas más bajas que los modelos 1-3 (Silhouette, Davies-Bouldin y Calinski-Harabasz), debido a que identificó un promedio de **1.396 clústeres**, frente a **5-6** en los modelos anteriores. Las métricas tradicionales favorecen pocos grupos bien definidos y penalizan la detección de **microclústeres**, lo cual no se alinea con el objetivo del proyecto.
- ▶ Aun así, el modelo 4 cumple con el requerimiento de desempeño:
 - Silhouette > 0, Davies-Bouldin bajo, Calinski-Harabasz alto
- ▶ A pesar del alto número de clústeres, el modelo logra separar adecuadamente comportamientos normales y anómalos.

Entregables & Demo

Prototipo API

Beneficios para el cliente

- Visualización clara del estado de riesgo y consumo.
- Ahorro de tiempo en análisis operativo.
- Priorización eficiente ante alertas críticas.
- Reportes exportables en PDF.
- Escalable a más variables y fuentes.

Características Técnicas

- Desplegado en entorno de pruebas Raywal para uso inmediato.
- Tecnología: Flask + Chart.js + HTML/CSS/JS.
- Backend con endpoints filtrables por cliente, fecha y riesgo.
- Frontend responsivo con gráficos dinámicos.
- Lectura desde Excel.
- Soporte para múltiples clientes y periodos.

Limitaciones actuales y siguientes pasos

- Aún no conectado a base de datos en producción.
- Sin autenticación de usuarios ni control de acceso.



<https://web-production-e3288.up.railway.app/>

Propuesta de Valor

► Diferencial respecto al status quo:

- Se identifican patrones de consumo atípico en forma de grupos o filamentos, lo que aumenta la probabilidad de detectar fugas reales y reduce falsos positivos.
- Menos inspecciones innecesarias, mayor eficiencia operativa y una mejor experiencia para el usuario final.

► Beneficios:

► Impacto directo en reputación y eficiencia operativa:

- Ahorros estimados en inspecciones y soporte: > **USD \$50,000 anuales** frente a una inversión inicial de ~USD \$250,000-\$300,000.
- Aumento de satisfacción de clientes evidente en reducción de PQRs.
- No se requiere optimización manual de parámetros (e.g., *min_samples*), pues el modelo está automatizado.

► Condiciones y riesgos:

- Capacitación al personal operativo con manual del usuario (resistencia al cambio)
- Limpieza continua de datos (inversión en auditorías)
- Acompañamiento en la integración al flujo de trabajo actual (riesgo humano)

Bibliografía

- PricingHUB. (2024, mayo 9). Outlier detection in time series using DBSCAN and SVR. Medium. <https://pricinghub.medium.com/outlier-detection-in-time-series-using-dbscan-and-svr-09b43d0cad1>